


Encuadra un proyecto de datos

Semana 1 · Corte 1 · Ciencia de Datos

PROYECTO PROPUESTO

Predicción de fallas en bombas centrífugas para mejorar la planificación del mantenimiento industrial



Programa	Ingeniería Industrial
Asignatura	Ciencia de Datos
Unidad	Fundamentos de Ciencia de Datos y Big Data
Modalidad	Individual o en parejas
Entrega	Repositorio en GitHub

Objetivo del proyecto: formular una pregunta de negocio clara, identificar los datos y fuentes necesarias y definir la decisión que habilitaría el resultado analítico.

1. Enunciado del problema

Problema real seleccionado: mantenimiento de equipos rotativos en una planta industrial. Las bombas centrífugas son activos críticos porque una falla puede detener o reducir la capacidad de producción y generar intervenciones no planificadas.

Contexto: actualmente, una parte del mantenimiento puede depender de calendarios fijos o de la reacción ante una alarma. La oportunidad de ciencia de datos consiste en aprovechar las señales de condición y el historial de mantenimiento para anticipar el riesgo de falla.

Pregunta de negocio:

¿Podemos predecir con suficiente anticipación qué bombas centrífugas tienen mayor probabilidad de presentar una falla en las próximas 24–48 horas, para priorizar inspecciones y programar mantenimiento antes de una parada no planificada?

Por qué esta pregunta es accionable: la respuesta no se limita a describir el pasado. Debe generar una lista priorizada de equipos y una recomendación concreta para mantenimiento: inspeccionar, programar intervención o continuar operación bajo monitoreo.

Decisión esperada

Resultado del modelo	Acción operativa
Riesgo alto	Priorizar inspección y programar mantenimiento según criticidad y disponibilidad de repuestos.
Riesgo medio	Aumentar monitoreo y revisar tendencias; preparar intervención si el riesgo crece.
Riesgo bajo	Continuar operación y mantener el plan preventivo normal.

2. Datos necesarios y fuentes

El proyecto debe integrar datos operativos de los equipos con información histórica de mantenimiento. La unidad de análisis puede ser **equipo–fecha/hora**, complementada por ventanas temporales de las señales de sensores.

Dato	Tipo	Fuente	Uso analítico
Temperatura de rodamiento/motor	Estructurado	Sensores / PLC / SCADA	Detectar calentamiento anormal y tendencia.
Vibración (RMS, pico, frecuencia)	Estructurado / series de tiempo	Sistema de monitoreo de condición	Identificar degradación mecánica.
Presión y caudal	Estructurado	Sensores / SCADA	Relacionar desempeño con condición operativa.
Corriente/consumo eléctrico	Estructurado	Medidor / PLC	Detectar cambios de carga o comportamiento.
Horas de operación y arranques	Estructurado	PLC / historiador	Contextualizar desgaste y exposición.
Órdenes, fallas y reparaciones	Estructurado / semiestructurado	CMMS / ERP / registros	Construir variable objetivo y antecedentes.
Informes, fotografías, observaciones	No estructurado	Mantenimiento / inspecciones	Aportar contexto y validar causas.

Fuentes prioritarias: SCADA/PLC para señales operativas; sensores de condición para vibración y temperatura; CMMS/ERP para mantenimiento, fallas y repuestos; y registros de inspección para complementar el contexto.


Variable objetivo propuesta: *Falla_24h = 1 si el equipo presenta una falla o evento de mantenimiento correctivo dentro de las siguientes 24 horas; 0 en caso contrario. Esta definición debe acordarse con*

el área de mantenimiento antes de entrenar el modelo.

3. Tipo de analítica y enfoque de Ciencia de Datos

Analítica principal: predictiva. El objetivo es estimar el riesgo de una falla futura a partir de señales actuales e históricas. Como apoyo, se utilizarían analítica descriptiva para conocer el comportamiento histórico y diagnóstica para investigar por qué se elevó el riesgo.

Tipo	Pregunta	Aplicación
Descriptiva	¿Qué ha ocurrido?	Tendencias de temperatura, vibración, fallas y paradas.
Diagnóstica	¿Por qué ocurrió?	Relacionar alarmas, condiciones de operación y antecedentes.
Predictiva	¿Qué puede ocurrir?	Estimar probabilidad/riesgo de falla en 24–48 h.



Flujo de trabajo propuesto:

- 1. Capturar y consolidar las señales y registros históricos.
- 2. Limpiar datos: valores faltantes, duplicados, unidades, sensores fuera de rango y marcas de tiempo.
- 3. Construir variables: medias, máximos, tendencia, cambios bruscos y estadísticas de ventanas temporales.
- 4. Definir la etiqueta de falla y separar entrenamiento/prueba respetando el orden temporal.
- 5. Entrenar y comparar modelos de clasificación, por ejemplo regresión logística, árbol/ensemble o modelos de series temporales según la cantidad y calidad de datos.
- 6. Evaluar no solo exactitud, sino precisión, recall, F1 y especialmente la capacidad de detectar fallas sin generar demasiadas falsas alarmas.
- 7. Convertir la predicción en una prioridad de mantenimiento y validar el resultado con expertos de planta.

4. Escalabilidad, Big Data y procesamiento


El proyecto puede evolucionar a un escenario de Big Data cuando múltiples equipos y sensores generan grandes volúmenes de series de tiempo, con alta velocidad y variedad de fuentes. En ese caso, la arquitectura debe separar captura, almacenamiento, procesamiento y consumo analítico.

V	Cómo aparece en el proyecto	Implicación
Volumen	Muchas bombas × sensores × lecturas históricas.	Almacenamiento escalable y compresión.
Velocidad	Lecturas frecuentes de sensores.	Procesamiento de streaming para alertas críticas.
Variedad	Series de tiempo, órdenes, textos e imágenes.	Integración de fuentes y formatos.
Veracidad	Sensores con ruido, faltantes o calibración imperfecta.	Calidad, trazabilidad y validación.

Valor	Menos paradas y mejores decisiones de mantenimiento.	Medir impacto operacional y económico.
-------	--	--

¿Lotes o tiempo real?

La recomendación es un enfoque híbrido. **Tiempo real** para detectar condiciones críticas y generar alertas rápidas; **procesamiento por lotes** para recalcular indicadores históricos, entrenar modelos, generar reportes y revisar tendencias. Así se evita exigir procesamiento instantáneo a tareas que no lo necesitan.



5. Decisión, indicadores y control del proyecto

La salida del proyecto debe ser comprensible para mantenimiento. Un tablero podría mostrar el equipo, nivel de riesgo, variables que contribuyen a la alerta, tendencia y acción recomendada. El modelo no reemplaza al profesional de mantenimiento: funciona como apoyo para priorizar recursos.

● Anticipación

horas/días de
alerta útil

● Disponibilidad

menos paradas
no planificadas

● Mantenimiento

mejor priorización
de órdenes

● Costo

menos intervenciones
innecesarias

Indicadores técnicos del modelo

Indicador	Qué responde
Recall de fallas	¿Qué proporción de las fallas reales logramos detectar?
Precisión	De las alertas generadas, ¿cuántas corresponden realmente a eventos de interés?
F1-score	¿Existe un equilibrio razonable entre precisión y recall?
Falsas alarmas	¿El sistema está generando demasiadas intervenciones innecesarias?
Anticipación	¿Con cuánta antelación útil se genera la alerta?

Riesgos y buenas prácticas:

- Evitar fuga de información: una variable registrada después de la falla no debe utilizarse para predecirla.
- Respetar el orden temporal al dividir los datos de entrenamiento y prueba.
- Controlar datos faltantes, sensores defectuosos y cambios de calibración.
- Registrar versiones del conjunto de datos, transformaciones y modelo.
- Mantener validación humana antes de convertir una alerta en una intervención de alto impacto.

6. Conclusión

La propuesta convierte un problema industrial concreto —las fallas no planificadas de bombas centrífugas— en una pregunta de negocio medible y accionable. La combinación de datos de sensores, SCADA/PLC y registros de mantenimiento permite construir un sistema de analítica predictiva que priorice equipos según su riesgo.

El valor del proyecto no está únicamente en obtener un modelo con buen desempeño estadístico, sino en **transformar la predicción en una decisión operativa**: qué equipo revisar, cuándo hacerlo y con qué prioridad. Un diseño híbrido de procesamiento en tiempo real y por lotes permite atender tanto las alertas críticas como el análisis histórico.

Como siguiente etapa, se recomienda realizar un inventario real de fuentes, verificar la calidad y frecuencia de los datos, definir con mantenimiento qué significa exactamente una “falla” y establecer una línea base antes de entrenar modelos. Esto convierte el ejercicio académico en un proyecto reproducible y escalable.

Entregable mínimo para GitHub: documento del proyecto + diccionario de datos + esquema de fuentes + notebook de exploración (cuando existan datos) + README con pregunta, decisión, metodología y resultados.

7. Referencias

Las siguientes fuentes se seleccionaron para sustentar los conceptos de Big Data, análisis de sensores y mantenimiento predictivo utilizados en la propuesta.

1. IBM. (s. f.). *Predictive maintenance*. IBM Think. <https://www.ibm.com/think/topics/predictive-maintenance>
2. IBM. (2015). *IBM Predictive Maintenance and Quality 2.0 Technical Overview*. IBM Redbooks. <https://www.redbooks.ibm.com/redpapers/pdfs/redp5035.pdf>
3. NIST. (2019). *NIST Big Data Interoperability Framework: Volume 1, Definitions*. National Institute of Standards and Technology. <https://www.nist.gov/publications/nist-big-data-interoperability-framework-volume-1-definitions>
4. NIST. (2019). *NIST Big Data Interoperability Framework: Volume 1, Definitions (SP 1500-1r2)*. <https://nvlpubs.nist.gov/nistpubs/SpecialPublications/NIST.SP.1500-1r2.pdf>
5. ISO. (2018). *ISO 17359:2018 — Condition monitoring and diagnostics of machines — General guidelines*. International Organization for Standardization.

Nota académica: las referencias sustentan el enfoque metodológico. Los valores, umbrales y resultados del proyecto deben calcularse con datos reales de la organización; en esta etapa no se inventan métricas de desempeño.