


Semana 2 · Clasifica datos y las V del Big Data

Ciencia de Datos · Corte 1 · Ingeniería Industrial

CASO INDUSTRIAL

Mantenimiento predictivo de bombas centrífugas

Clasificación de fuentes de datos, identificación de las 5 V y control de calidad de datos



Unidad	Unidad 1 · Fundamentos de Ciencia de Datos y Big Data
Semana / Corte	Semana 2 · Corte 1
Programa	Ingeniería Industrial
Asignatura	Ciencia de Datos
Entrega	Repositorio en GitHub · carpeta 02-week/

Objetivo: clasificar correctamente las fuentes del caso como estructuradas, semiestructuradas o no estructuradas; justificar las V de Big Data más relevantes; e identificar un problema concreto de veracidad y su método de detección.

1. Enunciado y contexto

Se mantiene el caso trabajado en la Semana 1: una planta industrial desea mejorar el mantenimiento de sus bombas centrífugas utilizando datos de sensores, sistemas de control y registros históricos. El propósito es identificar señales asociadas con degradación y apoyar la priorización de inspecciones y mantenimientos.

La pregunta de negocio es: ¿Qué equipos presentan mayor riesgo de falla y qué información de condición permite priorizar una intervención? Para responderla se necesita integrar fuentes con distintas estructuras y calidades.

2. Clasificación de fuentes de datos

Fuente	Ejemplo	Clasificación	Por qué
SCADA / PLC	Temperatura, presión, caudal, estados	Estructurado	Variables con campos, marcas de tiempo y valores definidos.
Sensores de vibración	RMS, picos, frecuencia, series temporales	Estructurado	Las mediciones se registran como variables numéricas asociadas al tiempo.
Medición eléctrica	Corriente, potencia, consumo	Estructurado	Lecturas cuantitativas con esquema conocido.
CMMS / ERP	Órdenes, fechas, activos, costos, repuestos	Estructurado	Registros tabulares con campos definidos.
Logs / exportaciones de equipos	JSON, XML, archivos con metadatos	Semiestructurado	Tienen estructura y etiquetas, pero no necesariamente una tabla fija.
Informes técnicos	Texto libre de inspecciones	No estructurado	El contenido no está organizado en un esquema tabular rígido.
Fotografías de inspección	Imágenes de sellos, rodamientos, tuberías	No estructurado	Son archivos visuales que requieren técnicas específicas para análisis.
Manuales / PDFs	Especificaciones y procedimientos	No estructurado	Su contenido puede contener texto, tablas e imágenes en un documento.

Resultado: se identifican más de seis fuentes y se incluyen las tres categorías exigidas. La clasificación depende de cómo se almacena y representa la información, no solamente de su origen.

3. ¿Qué V de Big Data son críticas?



Volumen: una planta con muchas bombas y sensores puede acumular millones de registros de series de tiempo. El reto es almacenar y consultar históricos sin perder trazabilidad.

Velocidad: las señales de condición pueden llegar con alta frecuencia. Es crítica cuando una variación rápida debe generar una alerta o activar una revisión.

Variedad: el proyecto combina series de tiempo, registros de mantenimiento, archivos JSON/XML, textos, fotografías y documentos. Integrar estas fuentes es uno de los principales retos.

Veracidad: es especialmente crítica porque un sensor con ruido, una marca de tiempo incorrecta o un registro de mantenimiento mal diligenciado puede producir falsas conclusiones y malas decisiones.

Valor: es la V que conecta la analítica con el negocio. Los datos deben convertirse en decisiones que reduzcan paradas no planificadas, mejoren la priorización y apoyen el uso eficiente de recursos.

Prioridad para este caso: Veracidad y Variedad son críticas desde el inicio; Volumen y Velocidad se vuelven más relevantes cuando aumenta la cantidad/frecuencia de sensores; Valor es el criterio que justifica todo el proyecto.

4. Reto de veracidad (calidad)

Problema propuesto: lecturas de vibración y temperatura con valores faltantes, duplicados o fuera de rango debido a fallas de comunicación, sensores descalibrados o problemas de registro.


¿Por qué es peligroso? Un valor anormal podría interpretarse como señal de una falla cuando en realidad corresponde a un error de medición. Esto puede aumentar las falsas alarmas o, en el caso contrario, ocultar una condición real de deterioro.

Plan de detección de calidad

- **Compleitud:** calcular el porcentaje de valores faltantes por sensor, equipo y periodo.
- **Rangos físicos:** establecer límites técnicos según especificaciones del equipo; valores imposibles o incompatibles deben marcarse para revisión.
- **Duplicados:** buscar registros repetidos con la misma marca de tiempo, equipo y variable.
- **Consistencia temporal:** verificar que las marcas de tiempo estén ordenadas, tengan la misma zona horaria y respeten la frecuencia esperada.
- **Detección de anomalías:** usar reglas estadísticas y de negocio para identificar saltos bruscos, valores constantes durante demasiado tiempo o patrones incompatibles con la operación.
- **Validación cruzada:** comparar variables relacionadas, por ejemplo temperatura, vibración, carga y estado del equipo, y contrastar con órdenes de mantenimiento.

Acción: los registros sospechosos no deben borrarse automáticamente. Deben conservarse, etiquetarse con su estado de calidad y documentar si fueron corregidos, imputados o excluidos del modelo.

5. Propuesta de flujo de datos



La arquitectura conceptual integra las fuentes en una capa de almacenamiento común. Después se aplica un proceso de calidad y transformación antes de utilizar los datos en tableros, análisis exploratorio o modelos predictivos. La trazabilidad debe permitir saber de dónde proviene cada dato y qué transformaciones recibió.

6. Tabla resumen para la entrega

Requisito	Respuesta del proyecto
6+ fuentes	SCADA/PLC, vibración, medición eléctrica, CMMS/ERP, logs JSON/XML, informes técnicos, fotografías y manuales/PDF.
Estructurado	SCADA/PLC, sensores, medición eléctrica, CMMS/ERP.
Semiestructurado	Logs y exportaciones JSON/XML con campos y metadatos.
No estructurado	Informes, fotografías, manuales y documentos PDF.
V críticas	Veracidad y variedad como prioridad; volumen, velocidad y valor según escala y uso del sistema.
Reto de veracidad	Datos faltantes, duplicados, fuera de rango y problemas de sincronización temporal.
Detección	Reglas de calidad, rangos físicos, completitud, duplicados, consistencia temporal, anomalías y validación cruzada.

7. Conclusión

La clasificación de los datos es una etapa fundamental antes de construir cualquier solución de Ciencia de Datos. En este caso, las fuentes estructuradas permiten trabajar con variables operativas y registros de mantenimiento; las semiestructuradas aportan información flexible de los sistemas; y las no estructuradas complementan el análisis con informes e imágenes.

Las cinco V permiten entender que el reto no consiste solamente en tener muchos datos. La **veracidad** es decisiva: si los datos son incorrectos, un modelo sofisticado puede producir una decisión equivocada. Por eso, la propuesta incorpora controles de calidad desde la captura hasta el consumo analítico.

8. Referencias

1. NIST. (2019). *NIST Big Data Interoperability Framework: Volume 1, Definitions* (Special Publication 1500-1r2). National Institute of Standards and Technology. <https://doi.org/10.6028/NIST.SP.1500-1r2>
2. Laney, D. (2001). *3D Data Management: Controlling Data Volume, Velocity and Variety*. META Group. Referencia clásica asociada a las dimensiones de volumen, velocidad y variedad de Big Data.
3. ISO. (2018). *ISO 17359:2018 — Condition monitoring and diagnostics of machines — General guidelines*. International Organization for Standardization.
4. IBM. (s. f.). *Predictive maintenance*. IBM Think. <https://www.ibm.com/think/topics/predictive-maintenance>
5. DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (2nd ed.). Technics Publications.

Nota: las fuentes y categorías de datos son una propuesta académica aplicada al caso de mantenimiento predictivo. Para una implementación real, las frecuencias de muestreo, límites físicos, reglas de calidad y fuentes definitivas deben validarse con la planta y sus responsables de mantenimiento, automatización y datos.