


DISEÑO DE UNA ARQUITECTURA DE DATOS

Propuesta profesional para el sector lácteo agroindustrial

Arquitectura propuesta para analítica del sector lácteo agroindustrial



Asignatura: Ciencia de Datos | **Programa:** Ingeniería Industrial

Semana 3 · Unidad 1 · Fundamentos de Ciencia de Datos y Big Data

Documento elaborado con enfoque de arquitectura de datos, escalabilidad, trazabilidad y analítica para la toma de decisiones.

1. Resumen ejecutivo

La presente propuesta diseña una arquitectura de datos para una organización del sector lácteo agroindustrial. El objetivo es integrar información procedente de fincas proveedoras, sistemas administrativos, producción, ventas, cadena de frío, distribución y sensores. La solución permite transformar datos dispersos en información confiable para controlar la operación, detectar desviaciones y apovar decisiones tácticas y estratégicas.

Decisión principal: se recomienda una arquitectura híbrida basada en **Data Lake** como repositorio central, procesamiento **batch + streaming**, transformación con **Apache Spark** y consumo mediante **Power BI**. Esta combinación permite conservar datos históricos y, al mismo tiempo, reaccionar ante eventos críticos como variaciones de temperatura en la cadena de frío.

Problema de negocio que resuelve


En la cadena láctea existen múltiples fuentes y ritmos de generación de datos: registros diarios de recepción de leche, inventarios, costos y ventas; además de eventos frecuentes generados por sensores de temperatura, equipos y logística. Sin una arquitectura integrada, la información puede quedar aislada en hojas de cálculo, bases transaccionales y dispositivos, dificultando la trazabilidad y la generación oportuna de indicadores.

Objetivos específicos

1	Centralizar datos estructurados y semiestructurados de toda la cadena láctea.
2	Conservar datos crudos y versiones procesadas para garantizar trazabilidad.
3	Procesar información histórica mediante batch y eventos críticos mediante streaming.
4	Generar indicadores para producción, calidad, cadena de frío, inventario, ventas y distribución.

2. Arquitectura de datos propuesta

Arquitectura propuesta para analítica del sector lácteo agroindustrial



Interpretación del flujo

Fuentes → Ingesta → Almacenamiento → Procesamiento → Análisis/BI. La arquitectura separa claramente las responsabilidades de cada capa. Las fuentes producen datos; la ingesta los captura; el Data Lake conserva las diferentes versiones; Spark transforma y valida; finalmente, la capa analítica presenta indicadores y permite

explorar tendencias.

Fuentes consideradas

Dominio	Ejemplos de datos	Frecuencia
Producción	Litros procesados, lote, rendimiento, tiempos	Por turno / diario
Calidad	pH, acidez, resultados de laboratorio, rechazos	Por lote
Cadena de frío	Temperatura, humedad, alarmas	Continuo
Ventas	Pedidos, clientes, productos, facturación	Diario / transaccional
Logística	Rutas, tiempos, entregas, GPS	Eventos / continuo
Finanzas e inventario	Costos, existencias, compras	Diario

3. ¿Data Lake o Data Warehouse?

Se selecciona **Data Lake como núcleo de almacenamiento**. La razón es que la organización debe integrar datos heterogéneos: tablas de ERP, archivos Excel/CSV, registros de laboratorio, eventos IoT y datos de logística. Un Data Lake permite conservar datos estructurados y no estructurados a escala y reutilizarlos para diferentes casos analíticos. Las arquitecturas modernas de lake también favorecen separar productores y consumidores de datos.


El Data Warehouse no se descarta: puede incorporarse posteriormente como una **capa de datos curados** o modelo dimensional para consultas ejecutivas de alto rendimiento. Por tanto, la propuesta evoluciona naturalmente hacia un enfoque tipo **lakehouse**.

Criterio	Data Lake (seleccionado)	Data Warehouse
Tipos de datos	Estructurados, semiestructurados y eventos	Principalmente estructurados y modelados
Flexibilidad	Alta para nuevas fuentes y casos de uso	Alta consistencia, menor flexibilidad inicial
Histórico crudo	Sí, conserva la fuente original	Normalmente se cargan datos transformados
IoT / sensores	Muy adecuado	Requiere procesos previos de integración
Uso recomendado aquí	Repositorio central y escalable	Capa analítica complementaria

Organización interna del Data Lake

Bronze: datos originales, sin alterar, con fecha y origen. **Silver:** datos limpios, validados y estandarizados. **Gold:** conjuntos agregados y listos para indicadores, modelos analíticos y BI. Esta separación facilita auditoría, reprocesamiento y trazabilidad de cada dato.

4. ¿Batch o Streaming?



Se recomienda un **modelo híbrido**. Batch se utiliza para procesos que no requieren respuesta inmediata: cierres diarios, consolidación de ventas, costos, inventarios y producción. Streaming se utiliza para variables operativas sensibles al tiempo, especialmente temperatura de tanques, cuartos fríos y transporte refrigerado.

Proceso	Modo	Justificación
Consolidación de ERP y ventas	Batch	Los datos pueden procesarse cada hora o al cierre del día.
Costos e inventario	Batch	Priorizan consistencia y consolidación periódica.
Temperatura cadena de frío	Streaming	Una desviación debe detectarse rápidamente para generar alertas.
Eventos de equipos / sensores	Streaming	Permite monitoreo y detección temprana de anomalías.
Analítica histórica	Batch	Trabaja con grandes volúmenes acumulados.

5. Herramientas candidatas por etapa

La selección se plantea como una arquitectura tecnológica realista y escalable. Las herramientas pueden ejecutarse en infraestructura local o en la nube según el presupuesto y la madurez digital de la empresa.

Etapas	Herramienta candidata	Rol dentro de la arquitectura	¿Por qué?
Ingesta batch	Airbyte + Python	Extraer ERP, bases SQL y archivos	Conectores y automatización de cargas periódicas.
Ingesta streaming	Apache Kafka	Capturar eventos y telemetría	Diseñado para publicar, almacenar y procesar flujos de eventos.
Almacenamiento	S3 / MinIO	Data Lake por zonas	Almacenamiento de objetos escalable y económico.
Procesamiento	Apache Spark	ETL, calidad, agregaciones y streaming	Procesamiento distribuido y soporte para analítica a gran escala.
Orquestación	Apache Airflow	Programar y supervisar pipelines	Permite dependencias, reintentos y trazabilidad operacional.
Calidad	Great Expectations	Validar reglas de negocio	Automatiza pruebas sobre datos antes de publicarlos.
BI	Microsoft Power BI	Dashboards y análisis ejecutivo	Conecta modelos de datos con visualizaciones interactivas.

Herramientas principales justificadas

Apache Kafka: es apropiado para eventos porque su arquitectura permite publicar, almacenar y consumir flujos de eventos de forma desacoplada. **Apache Spark:** es adecuado para transformación y procesamiento de datos, incluyendo capacidades de streaming. **Power BI:** permite convertir datos curados y modelos semánticos en reportes y visualizaciones para usuarios de negocio.

6. Gobierno, calidad y seguridad de los datos

Una arquitectura profesional no termina en el almacenamiento. Para que los indicadores sean confiables se requiere gobierno de datos: definición de propietarios, catálogo, reglas de calidad, control de acceso y monitoreo.

Componente	Aplicación propuesta
Catálogo y metadatos	Registrar origen, responsable, frecuencia, definición y esquema de cada conjunto de datos.
Calidad	Validar campos obligatorios, rangos de temperatura, duplicados, unidades y consistencia de fechas.
Trazabilidad	Conservar origen y transformaciones desde Bronze hasta Gold.
Seguridad	Roles por área, mínimo privilegio, cifrado y auditoría de accesos.
Observabilidad	Medir retrasos, errores, volumen procesado y disponibilidad de los pipelines.

Ejemplos de reglas de calidad

- La temperatura debe incluir unidad y marca de tiempo.
- Cada lote debe tener un identificador único.
- Los registros de recepción no pueden contener cantidades negativas.
- La fecha de vencimiento debe ser posterior a la fecha de producción.
- Las mediciones anómalas deben conservarse, pero marcarse para revisión y no eliminarse sin trazabilidad.

7. Indicadores y productos analíticos

La capa Gold alimentará dashboards orientados a operaciones y dirección. Los principales productos analíticos serían:

Área	Indicadores sugeridos
Producción	Litros procesados, rendimiento por lote, merma, tiempo de ciclo.
Calidad	Porcentaje de lotes conformes, rechazos, resultados fuera de especificación.
Cadena de frío	Temperatura promedio, número de desviaciones, tiempo fuera de rango.
Inventario	Rotación, días de cobertura, productos próximos a vencer.
Ventas	Ingresos, unidades, crecimiento, productos más demandados.
Logística	Entregas a tiempo, duración de rutas, incidencias de transporte.
Sostenibilidad	Consumo energético por litro procesado y generación de residuos.

Ejemplo de dashboard ejecutivo

Un tablero principal puede mostrar: producción del día, porcentaje de cumplimiento de temperatura, inventario crítico, ventas acumuladas y alertas activas. Desde allí se habilita el detalle por planta, producto, lote, proveedor, ruta y periodo.

8. Plan de implementación recomendado

Fase	Duración estimada	Entregable
1. Diagnóstico	1–2 semanas	Inventario de fuentes, responsables y casos de uso prioritarios.
2. Data Lake inicial	2 semanas	Zonas Bronze/Silver/Gold y convenciones de almacenamiento.
3. Pipelines batch	2–3 semanas	Integración de ERP, ventas, producción e inventario.
4. Streaming piloto	2 semanas	Captura de temperatura y generación de alertas.
5. Procesamiento y calidad	2–3 semanas	Transformaciones Spark y reglas de validación.
6. BI	1–2 semanas	Modelo analítico y dashboards con KPIs.
7. Gobierno y mejora	Continuo	Monitoreo, seguridad, documentación y optimización.

Conclusión

La arquitectura propuesta responde a las necesidades reales de una cadena láctea agroindustrial porque integra datos de distinta naturaleza y velocidad. El **Data Lake** aporta flexibilidad y trazabilidad; el enfoque **batch + streaming** permite combinar análisis histórico con monitoreo oportuno; **Spark** proporciona una capa de transformación escalable; y **Power BI** convierte los datos curados en decisiones comprensibles para producción, calidad, logística y dirección.

Recomendación final: comenzar con un piloto de alto valor y alcance controlado —por ejemplo, integrar producción + temperatura de cadena de frío— y después incorporar ventas, inventario, costos y analítica predictiva. De esta manera se obtiene valor temprano sin perder la visión de una plataforma de datos escalable.

9. Referencias

Apache Kafka. (2026). *Introduction: Event streaming and Apache Kafka documentation*. <https://kafka.apache.org/documentation/>

Apache Spark. (2026). *Apache Spark Documentation*. <https://spark.apache.org/documentation>

Amazon Web Services. (2026). *Designing a data lake for growth and scale on the AWS Cloud*. AWS Prescriptive Guidance. <https://docs.aws.amazon.com/prescriptive-guidance/latest/data-lake-for-growth-scale/introduction.html>

Amazon Web Services. (2026). *Reference architecture: Data lake for growth and scale*. AWS Prescriptive Guidance. <https://docs.aws.amazon.com/prescriptive-guidance/latest/data-lake-for-growth-scale/reference-architecture.html>

Microsoft. (2026). *Power BI documentation*. Microsoft Learn. <https://learn.microsoft.com/power-bi/>

Microsoft. (2026). *Overview of Power BI reports and visualizations*. Microsoft Learn. <https://learn.microsoft.com/en-us/power-bi/>

Nota metodológica

Las decisiones de arquitectura se sustentan en principios de integración de múltiples fuentes, escalabilidad, separación entre productores y consumidores, procesamiento de eventos y consumo analítico. Las herramientas citadas son candidatas tecnológicas; su implementación concreta debe ajustarse al presupuesto, infraestructura, talento y requisitos de seguridad de la organización.

Documento académico — Ciencia de Datos · Ingeniería Industrial · CORHUILA