

Diagnóstico de Datos de un Proceso

Actividad Calificable - Corte 1 (Semana 4)

Estudiante / Usuario: Profesional en Ciencia de Datos

Valor Actividad: 5.0 / 5.0

Entregable: Repositorio GitHub (Fork del curso)

Perfil Config: CONFIG (FULL_NAME + GITHUB_USER)

1. Selección del Proceso y Pregunta de Datos

Proceso Seleccionado: Mantenimiento Predictivo y Optimización Operativa en una Planta de Compresión de Gas Natural (Sector Industrial / Energético).

Contexto Operativo: Las plantas de compresión de gas natural operan de manera continua bajo altas presiones y temperaturas. Las fallas no planificadas en los motocompresores industriales generan costosas paradas de producción, riesgos de seguridad industrial e impacto ambiental por venteo de gas.

Pregunta Principal de Ciencia de Datos:

"¿Cómo evaluar y predecir la probabilidad de falla inminente por sobrecalentamiento o vibración excesiva en los motocompresores de gas dentro de las próximas 48 horas, y cuál es la estrategia óptima de mantenimiento para maximizar el tiempo de disponibilidad operacional?"

2. Inventario de Datos (6 Fuentes / Campos)

Para abordar la pregunta de datos planteada, se estructuró el siguiente inventario de información combinando datos de sensores telemétricos, logs de infraestructura y registros operativos:

#	Nombre del Campo / Fuente	Clasificación de Datos	Descripción y Formato
1	telemetry_vibration_hz	ESTRUCTURADO	Lecturas en tiempo real de acelerómetros en cojinetes (frecuencia en Hz, float). Almacenado en base de datos de series temporales (Time-Series DB).
2	exhaust_temp_celsius	ESTRUCTURADO	Medición continua de la temperatura de escape de cilindros en °C (Numérico flotante). Almacenado en tablas SQL transaccionales del SCADA.
3	scada_event_logs	SEMIESTRUCTURADO	Registros de eventos y alarmas del sistema en formato JSON (incluye campos como timestamp, event_id, severity_level, error_code).
4	maintenance_work_orders	SEMIESTRUCTURADO	Órdenes de trabajo digitales e historial de intervenciones en archivos XML/JSON exportados del sistema ERP (SAP PM/ Maximo).
5	technician_field_notes	NO ESTRUCTURADO	Texto libre ingresado por técnicos de campo detallando síntomas observados, ruidos anómalos o reemplazos de piezas en lenguaje natural.
6	thermal_camera_images	NO ESTRUCTURADO	Imágenes termográficas infrarrojas (archivos PNG/RAW) capturadas durante inspecciones periódicas de los cabezales y válvulas del compresor.

3. Tipo de Analítica Aplicada y Justificación Big Data (V's)

3.1. Progresión Analítica (Descriptiva → Prescriptiva)

El proyecto contempla una evolución a través de los cuatro niveles de analítica de datos:

- **Analítica Descriptiva:** Monitoreo de tableros con KPI clave (temperatura promedio, nivel de vibración RMS, horas continuas de operación) e historial de paradas no programadas.
- **Analítica Diagnóstica:** Análisis de causa raíz (RCA) mediante correlación de datos (ej. relacionar picos de vibración con variaciones abruptas en la presión de succión).
- **Analítica Predictiva:** Implementación de modelos de Machine Learning (ej. *XGBoost*, *LSTM Neural Networks*) para predecir la probabilidad de falla inminente ($P(Falla) > 0.85$) en las siguientes 48 horas.
- **Analítica Prescriptiva:** Algoritmos de optimización de operaciones que recomiendan automáticamente la acción técnica óptima (ej. "reducir la carga del motor al 75% y programar mantenimiento preventivo a las 02:00 AM").

3.2. Justificación como Caso de Big Data (Dimensiones de las "V's")

Este proyecto clasifica plenamente como un caso de **Big Data** justificable bajo el marco de las 5 "V":

- **Volumen:** Generación masiva de datos telemétricos a alta frecuencia (100 Hz por sensor en múltiples motocompresores), acumulando gigabytes diarios de información continua.

- **Velocidad:** Ingesta y procesamiento de streams de datos en tiempo casi real mediante arquitecturas como Apache Kafka para detección temprana de anomalías antes de que ocurra una avería física.
- **Variedad:** Manejo simultáneo de datos relacionales estructurados (series temporales), datos semiestructurados (logs JSON/XML) y datos no estructurados (texto libre e imágenes termográficas).
- **Veracidad:** Necesidad de filtrado, reducción de ruido por sensores defectuosos e imputación de valores faltantes para garantizar la calidad de las predicciones operacionales.
- **Valor:** Transformación de los datos en valor económico directo: mitigación de paradas no planificadas (ahorros estimados en cientos de miles de dólares por horas de inactividad evitada) y aumento de la vida útil de los equipos.

4. Ciclo de Vida del Proyecto de Ciencia de Datos

El flujo metodológico implementado para resolver el problema sigue las seis etapas continuas del ciclo de vida del dato:

1. PREGUNTA (Problem Framing)

Definir el objetivo de negocio: reducir las fallas no planificadas en los compresores de gas natural y predecir sobrecalentamientos/vibraciones 48h antes.

2. OBTENER (Data Ingestion)

Ingestar streams de sensores IoT mediante protocolos MQTT/Kafka, realizar extracción via API de la base de datos SCADA y consultar los logs del sistema ERP.

3. LIMPIAR (Data Preprocessing & Wrangle)

Eliminar ruido de señales telemétricas, imputar valores faltantes por lecturas descalibradas, tokenizar notas de técnicos (NLP) y estandarizar marcas temporales (timestamps).

4. ANALIZAR (Modeling & Analytics)

Entrenar modelos de detección de anomalías e inferencia predictiva (Random Forest, XGBoost, modelos de series temporales LSTM) para calcular $P(\text{Falla})$.

5. VISUALIZAR (Dashboarding & Reporting)

Desplegar tableros interactivos en Grafana/PowerBI con alertas en tiempo real, mapas de calor de riesgo térmico y métricas de desempeño operacional.

6. DECIDIR (Decision Making & Action)

Generar órdenes de trabajo automáticas para mantenimiento preventivo, ajustar la carga operativa de las máquinas y validar el ROI del modelo analítico.

5. Requisito en Inglés (20%) — README Section: "Problem & Data"

README.md • Section: Problem & Data

"Industrial gas compression plants frequently face unplanned equipment downtime caused by severe overheating and mechanical vibration anomalies in motor-compressor units. To solve this operational bottleneck, this project aims to predict critical equipment failures up to 48 hours in advance using advanced data analytics. The required dataset combines high-frequency structured IoT telemetry (vibration and temperature sensor streams), semi-structured JSON system event logs, and unstructured natural language field notes written by maintenance personnel. We will transition from descriptive analytics and monitoring dashboards to predictive models using machine learning to calculate failure probability. Ultimately, prescriptive recommendations will be generated to automatically schedule maintenance work orders and prevent catastrophic machinery failures."

6. Referencias Bibliográficas

1. Provost, F., & Fawcett, T. (2013). *Data Science for Business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.
2. Hashem, I. A. T., Yaqoob, I., Anuar, N. B., Mokhtar, S., Gani, A., & Khan, S. U. (2015). The rise of "big data" on cloud computing: Review and open research issues. *Information Systems*, 47, 98-115.
3. Mobley, R. K. (2002). *An introduction to predictive maintenance*. Elsevier.
4. Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann.