

ENTREGA — DATA & CLEANING


Proyecto de análisis de datos con Python, pandas y ERD

Estudiante: Gener Valencia

Fecha: Octubre de 2026

1. Diseño del ERD

El modelo representa un sistema de ventas e-commerce con Clientes, Pedidos, DetallePedido y Productos. Las relaciones son: Clientes 1:N Pedidos, Pedidos 1:N DetallePedido y Productos 1:N DetallePedido.



ERD — Sistema de ventas e-commerce

Figura 1. Diagrama entidad-relación.

2. Dataset y limpieza

El dataset de práctica contiene 36 registros y 12 columnas antes de la limpieza. Se incorporaron problemas controlados para demostrar el tratamiento de nulos, duplicados, tipos, formatos y valores inválidos.

Indicador	Antes	Después
Filas	36	35
Columnas	12	13
Nulos	3	0
Duplicados	1	0

Se eliminaron duplicados, se normalizaron textos, se estandarizaron fechas, se corrigieron tipos numéricos, se trató la cantidad negativa, se imputaron valores faltantes y se calculó revenue = quantity × unit_price.

3. Consultas y hallazgos

Pregunta 1: ¿Qué categoría generó mayores ingresos?

```
df.groupby("category")["revenue"].sum().sort_values(ascending=False)
```

Hallazgo: **Tecnología** lideró con **\$20,940,000 COP**.

Categoría	Ingresos (COP)
Tecnología	\$20,940,000
Oficina	\$8,135,000

Pregunta 2: ¿Qué ciudad tuvo el mayor valor promedio por pedido?

```
order_values = df.groupby(["order_id", "city"])["revenue"].sum().reset_index()
order_values.groupby("city")["revenue"].mean().sort_values(ascending=False)
```

Hallazgo: **Neiva** presentó el mayor ticket promedio, con **\$1,105,000 COP**.

Ciudad	Ticket promedio (COP)
Neiva	\$1,105,000
Pitalito	\$988,571
Garzon	\$709,167
Aipe	\$334,286
Desconocida	\$90,000

4. "Data & cleaning" — English requirement

The dataset represents a small e-commerce sales operation in several cities of Huila, Colombia. It contains customers, orders, products, quantities, prices, payment methods, and order status. The raw data included missing values, one duplicated record, inconsistent capitalization, mixed date formats, and an invalid negative quantity. The cleaning process standardized text fields, converted dates and numeric columns, removed the duplicated row, replaced missing values, corrected the invalid quantity, and calculated revenue. After cleaning, the dataset contains 35 records with no missing values or duplicated rows. The first question compares total revenue by product category, while the second calculates the average order value by city. The results show that Tecnología produced the highest revenue and Neiva had the highest average order value.

5. Estructura de entrega

El proyecto incluye el CSV original, el CSV limpio, el script de pandas, el ERD y este informe. Los archivos pueden copiarse directamente a la carpeta de la semana correspondiente del fork de GitHub.

6. Referencias

McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.

pandas development team. (2026). pandas documentation: User Guide. <https://pandas.pydata.org/docs/>

Elmasri, R., & Navathe, S. B. (2016). Fundamentals of Database Systems (7th ed.). Pearson.