

Auditoría y Limpieza de Calidad de Datos


CORHUILA • Ingeniería Industrial • Ciencia de Datos (Semana 9)

Informe Técnico
Corte 2 - 2026-B

FULL_NAME: Estudiante Ciencia de Datos GITHUB_USER: github-user-corhuila CARPETA: 09-week/

1. Pipeline de Refinamiento e Higiene de Datos

Se diseñó una canalización sistemática con Pandas para transformar un dataset sucio proveniente de operaciones industriales (con valores nulos, registros duplicados, inconsistencias sintácticas y tipos erróneos) en un dataset apto para analítica avanzada.



2. Reporte Cuantitativo Antes vs. Después

Métricas comparativas obtenidas tras ejecutar la canalización de procesamiento sobre la muestra de datos operacionales:

Métrica de Calidad	Estado Inicial (Antes)	Estado Final (Después)	Impacto Obtenido
Número de Filas Totales	10 Filas	8 Filas	Eliminación de 2 registros duplicados redundantes.
Valores Nulos / Faltantes	6 Valores Nulos	0 Valores Nulos	Imputación estadística (mediana/moda) y remoción crítica.
Registros Duplicados Exactos	2 Duplicados	0 Duplicados	Deduplicación mediante drop_duplicates().
Tipo Columna Fecha	object (String heterogéneo)	datetime64[ns]	Estandarización ISO 8601 para series de tiempo.
Normalización de Texto	Minúsculas, Mayúsculas, Espacios	Title Case / Clean text	Limpieza de espacios extremos (strip()) y formato.

3. Script de Limpieza en Python (Pandas)

El siguiente código fuente autónomo genera la estructura con anomalías, ejecuta las etapas de auditoría, corrección e imputación, e imprime los reportes de calidad correspondientes:

```
# Script de Limpieza y Control de Calidad de Datos - Semana 09
import pandas as pd
import numpy as np

# 1. CREACIÓN DEL DATASET CON DEFECTOS DE CALIDAD (SIMULACIÓN CRUDA)
raw_data = {
    'ID_Pedido': [101, 102, 103, 104, 104, 105, 106, 107, 108, 108],
    'Cliente': ['carlos perez ', 'ANA GOMEZ', 'carlos perez', 'LUIS DIAZ', 'LUIS DIAZ', 'marta suare
z', np.nan, 'PEDRO RUIZ', 'MARIA LOPEZ', 'MARIA LOPEZ'],
    'Monto_COP': ['150000', '200000', np.nan, '350000', '350000', '180000', '120000', 'ERROR', '50000
0', '500000'],
    'Fecha_Registro': ['2026-09-01', '02/09/2026', '2026-09-03', '2026-09-04', '2026-09-04', np.nan,
'2026-09-06', '2026-09-07', '2026-09-08', '2026-09-08']
}
df = pd.DataFrame(raw_data)

# 2. AUDITORÍA INICIAL (ANTES)
filas_antes = len(df)
nulos_antes = df.isnull().sum().sum()
duplicados_antes = df.duplicated().sum()

# 3. TRANSFORMATION & CLEANING PIPELINE
# a) Eliminar duplicados exactos
df = df.drop_duplicates().reset_index(drop=True)

# b) Normalizar texto (Nombres de clientes)
df['Cliente'] = df['Cliente'].fillna('Cliente Anonimo').astype(str).str.strip().str.title()

# c) Corrección de tipos e imputación de Monto_COP
df['Monto_COP'] = pd.to_numeric(df['Monto_COP'], errors='coerce')
mediana_monto = df['Monto_COP'].median()
df['Monto_COP'] = df['Monto_COP'].fillna(mediana_monto)

# d) Homogeneización de fechas a datetime64
df['Fecha_Registro'] = pd.to_datetime(df['Fecha_Registro'], format='mixed', errors='coerce')
df['Fecha_Registro'] = df['Fecha_Registro'].fillna(method='ffill')

# 4. AUDITORÍA FINAL (DESPUÉS)
filas_despues = len(df)
nulos_despues = df.isnull().sum().sum()
duplicados_despues = df.duplicated().sum()

print(f"Antes -> Filas: {filas_antes}, Nulos: {nulos_antes}, Duplicados: {duplicados_antes}")
print(f"Después -> Filas: {filas_despues}, Nulos: {nulos_despues}, Duplicados: {duplicados_despues}")
```

4. Dimensiones de Calidad de Datos Mejoradas

1. Completitud (Completeness)

Definición: Grado en el que todos los datos requeridos están presentes en el dataset sin omitir valores esenciales para el análisis.

Mejora Aplicada: Se erradicó el 100% de los valores nulos (NaN/None). En variables críticas numéricas (Monto_COP), se aplicó imputación por la mediana para evitar sesgos por sesgo estadístico sin perder registros operacionales.

2. Consistencia y Conformidad

Definición: Homogeneidad en los formatos de presentación, sintaxis y tipos de datos a lo largo de todas las observaciones.

Mejora Aplicada: Estandarización de cadenas de texto (eliminación de espacios residuales y conversión a Title Case) y casteo explícito de fechas heterogéneas al estándar ISO 8601 nativo de Pandas (datetime64).

